

COLA DE PROVA

MÉTODOS ESTATÍSTICOS APLICADOS ÀS CIÊNCIAS SOCIAIS

Guia prático baseado no gabarito da avaliação

OBJETIVO: usar este documento como um manual durante a prova. Primeiro identifique o tipo de variável e o que a questão pede; depois copie o bloco de código correspondente, troque os nomes das variáveis e interprete o resultado.

1. ANTES DE COMEÇAR

Imports

```
import pandas as pd
import altair as alt
```

```
alt.data_transformers.disable_max_rows()
```

Abrir CSV com ;

```
dados = pd.read_csv('arquivo.csv', sep=';')
```

Abrir CSV com ,

```
dados = pd.read_csv('arquivo.csv')
```

Olhar os dados

```
dados.head()
dados.dtypes
```

Mostrar todas as colunas

```
pd.set_option('display.max_columns', None)
```

2. PRIMEIRA COISA: IDENTIFIQUE O TIPO DA VARIÁVEL

Variável qualitativa = categoria. Exemplos: sexo, cor/raça, tipo de escola, acesso à internet.

Variável quantitativa = número/quantidade. Exemplos: renda, esperança de vida, mortalidade infantil, taxa de analfabetismo, temperatura, chuva.

Variável de tempo = data.

```
QUALITATIVA → barras / pizza / tabela de dupla entrada
QUANTITATIVA → histograma / describe()
TEMPO → gráfico de linha
```

3. UMA VARIÁVEL QUALITATIVA — GRÁFICO DE BARRAS

Quando usar: uma variável qualitativa sozinha.

```
alt.Chart(dados).mark_bar().encode(
    alt.X("VARIÁVEL", sort='-y'),
    alt.Y('count()'),
    tooltip=['VARIÁVEL', 'count()']
)
```

Exemplo do gabarito:

```
alt.Chart(enem).mark_bar().encode(
    alt.X("TP_COR_RACA", sort='-y'),
    alt.Y('count()'),
    tooltip=['TP_COR_RACA', 'count()']
).properties(width=300)
```

Interpretação: diga qual categoria é mais frequente, qual é menos frequente e onde existe maior concentração.

Frase-modelo:

"A categoria X apresenta a maior frequência, enquanto Y apresenta a menor frequência. Observa-se maior concentração das observações em X."

4. UMA VARIÁVEL QUALITATIVA — GRÁFICO DE PIZZA

Quando usar: uma variável qualitativa, especialmente quando a questão pedir proporções/participação.

```
alt.Chart(dados).mark_arc().encode(
    theta="count()",
    color="VARIÁVEL",
    tooltip=['VARIÁVEL', 'count()']
)
```

Exemplo:

```
alt.Chart(enem).mark_arc().encode(
    theta="count()",
    color="TP_SEX0",
    tooltip=['TP_SEX0', 'count()']
)
```

5. DUAS VARIÁVEIS QUALITATIVAS — TABELA DE DUPLA ENTRADA

Quando usar: duas variáveis qualitativas. Exemplo: cor/raça × acesso à internet.

```
tabela = dados.groupby(
    ['VARIÁVEL1', 'VARIÁVEL2']
).size().unstack(1)
```

Exemplo do gabarito:

```
tabela_dupla_entrada = enem.groupby(
    ['TP_COR_RACA', 'Q025']
).size().unstack(1)
```

O que cada parte faz: groupby() = agrupa; size() = conta; unstack(1) = organiza a tabela.

6. PORCENTAGEM CONDICIONAL

Se a questão pedir a distribuição da segunda variável dentro de cada categoria da primeira:

```
tabela / tabela.groupby(level=0).transform(sum) * 100
```

Se a questão inverter a direção:

```
tabela / tabela.groupby(level=1).transform(sum) * 100
```

DECORAÇÃO: level=0 = primeira variável; level=1 = segunda variável.

Interpretação: se você usou level=0, pense: 'Dentro de cada categoria da primeira variável, como a segunda se distribui?'

Frase-modelo:
"Dentro da categoria X de VARIÁVEL1, aproximadamente Y% pertencem à categoria Z de VARIÁVEL2."

7. BARRAS PARA DUAS QUALITATIVAS

```
aux = (
    tabela /
    tabela.groupby(level=0).transform(sum) * 100
).reset_index().rename(columns={0: 'contagem'})

alt.Chart(aux).mark_bar().encode(
    x='VARIÁVEL1:N',
    y='contagem:Q',
    color='VARIÁVEL2:N'
)
```

8. VARIÁVEL QUANTITATIVA — DESCRIBE()

```
dados["VARIÁVEL"].describe()
```

count = quantidade; mean = média; std = desvio padrão; min = mínimo; 25% = Q1; 50% = mediana; 75% = Q3; max = máximo.

Decore especialmente: 25% = Q1; 50% = mediana; 75% = Q3.

9. HISTOGRAMA

Quando usar: analisar a distribuição de uma variável quantitativa.

```
alt.Chart(dados).mark_bar().encode(
    alt.X("VARIABEL", bin=True),
    y='count()'
)
```

Ao interpretar, observe: concentração, valores altos/baixos, simetria, assimetria e possíveis valores extremos.

10. MÉDIA × MEDIANA × ASSIMETRIA

MÉDIA > MEDIANA → tendência à assimetria à direita
MÉDIA < MEDIANA → tendência à assimetria à esquerda
MÉDIA ≈ MEDIANA → distribuição mais próxima de simétrica

Quando média > mediana: poucos valores altos podem puxar a média para cima.

Frase-modelo:
"A média é superior à mediana, indicando uma distribuição assimétrica à direita, com valores elevados puxando a média para cima."

11. ORDENAR OS DADOS

```
dados[["Territorialidades", "Renda per capita 2010"]].sort_values(
    "Renda per capita 2010",
    ascending=False
)
```

ascending=False = maior para menor. ascending=True = menor para maior.

12. FILTRAR VALORES ACIMA DE UM LIMITE

```
dados[dados["VARIABEL"] > VALOR]
```

Exemplo:

```
censo_municipios[censo_municipios["Mortalidade infantil 2010"]>45][
    ["Territorialidades", "Mortalidade infantil 2010"]
]
```

13. SÉRIE TEMPORAL — CONVERTER DATA

```
dados['DATA (YYYY-MM-DD)'] = pd.to_datetime(
    dados['DATA (YYYY-MM-DD)']
)
```

14. SÉRIE TEMPORAL — GRÁFICO DE LINHA

```
alt.Chart(dados).mark_line().encode(
    x='DATA (YYYY-MM-DD)',
    y=alt.Y('VARIABEL:Q'),
    tooltip=['DATA (YYYY-MM-DD)', 'VARIABEL']
)
```

Interprete: tendência, picos, mínimos, ciclos e períodos sem dados.

15. MÉDIA MENSAL

```
dados_index = dados.set_index('DATA (YYYY-MM-DD)')
dados_mensal = dados_index.resample('M').VARIABEL.mean()
```

Lógica: set_index → coloca a data como índice; resample('M') → agrupa por mês; mean() → calcula a média.

16. DUAS VARIÁVEIS QUANTITATIVAS — SCATTERPLOT

```
alt.Chart(dados).mark_circle().encode(
    alt.X("VARIABEL1"),
    alt.Y("VARIABEL2"),
    tooltip=['Territorialidades', 'VARIABEL1', 'VARIABEL2']
)
```

X aumenta e Y aumenta → relação positiva. X aumenta e Y diminui → relação negativa. Pontos muito espalhados → relação linear mais fraca.

17. PEARSON

```
dados[['VARIABEL1', 'VARIABEL2']].corr(numeric_only=True)

dados.corr(numeric_only=True)
```

positivo → relação linear positiva; negativo → relação linear negativa; perto de +1 ou -1 → relação linear mais forte; perto de 0 → relação linear mais fraca.

IMPORTANTE: Pearson fala de relação linear. Não conclua causalidade apenas porque existe correlação.

18. OUTLIERS E CORRELAÇÃO

Um ponto muito diferente dos demais pode influenciar bastante o coeficiente de Pearson.

O que você precisa saber: se a correlação muda muito quando um ponto é retirado, esse ponto estava influenciando o resultado.

19. BOXPLOT — COMPARAR DISTRIBUIÇÕES

Quando usar: comparar a distribuição de uma variável quantitativa entre grupos.

```
melted_data = dados.melt(
    id_vars=['Territorialidades'],
    value_vars=['VARIABEL_HOMEM', 'VARIABEL_MULHER'],
    var_name='Category',
    value_name='Value'
)

alt.Chart(melted_data).mark_boxplot(
    extent=1.5,
    size=40
).encode(
    alt.X("Value:Q"),
    alt.Y("Category:N")
)
```

melt() = reorganiza os dados para facilitar a comparação no boxplot.

20. COMO LER UM BOXPLOT

Observe: mediana, Q1, Q3, tamanho da caixa, dispersão, possíveis outliers e assimetria.

$AIQ = Q3 - Q1$

AIQ = amplitude interquartil.

21. FRASES PRONTAS PARA INTERPRETAR

Concentração:

"A categoria X apresenta a maior frequência, enquanto Y apresenta a menor frequência."

Assimetria à direita:

"A distribuição apresenta assimetria à direita, com concentração em valores menores e uma cauda em direção aos valores maiores."

Assimetria à esquerda:

"A distribuição apresenta assimetria à esquerda, com concentração em valores maiores e uma cauda em direção aos valores menores."

Relação positiva:

"Observa-se uma relação linear positiva: valores maiores de X tendem a estar associados a valores maiores de Y."

Relação negativa:

"Observa-se uma relação linear negativa: valores maiores de X tendem a estar associados a valores menores de Y."

Pearson:

"O coeficiente de Pearson indica uma relação linear [positiva/negativa] de intensidade [fraca/moderada/forte] entre as variáveis X e Y."

Série temporal:

"A série apresenta variações ao longo do tempo, com períodos de maior e menor intensidade e possível comportamento cíclico."

Boxplot:

"As distribuições apresentam diferenças em relação à mediana e à dispersão, sendo possível observar também a presença de outliers."

22. SE APARECER UM CSV NOVO NA PROVA

```
dados = pd.read_csv('arquivo.csv')
dados.head()
dados.dtypes
```

Depois identifique: qualitativa → sexo, raça, categoria etc.; quantitativa → idade, renda, temperatura etc.; tempo → data.

23. MAPA DE DECISÃO

UMA QUALITATIVA
→ barras ou pizza

DUAS QUALITATIVAS
→ tabela de dupla entrada
→ porcentagem condicional

UMA QUANTITATIVA
→ histograma
→ describe()

TEMPO
→ pd.to_datetime()
→ gráfico de linha
→ resample('M') se pedir média mensal

DUAS QUANTITATIVAS
→ scatterplot
→ Pearson

COMPARAR DISTRIBUIÇÕES
→ boxplot
→ $AIQ = Q3 - Q1$

24. COLA DE 30 SEGUNDOS

QUALITATIVA → barras / pizza
2 QUALITATIVAS → groupby + size + unstack
PORCENTAGEM → groupby(level=0) ou level=1
QUANTITATIVA → histograma + describe()
TEMPO → datetime + linha
MENSAL → resample('M')
2 QUANTITATIVAS → scatter + corr()
COMPARAR GRUPOS → boxplot
 $AIQ \rightarrow Q3 - Q1$

MÉDIA > MEDIANA → assimetria à direita
MÉDIA < MEDIANA → assimetria à esquerda

PEARSON + → relação positiva
PEARSON - → relação negativa
PERTO DE ± 1 → mais forte
PERTO DE 0 → mais fraca

SEMPRE INTERPRETAR O RESULTADO.

25. ORDEM DE PRIORIDADE PARA ESTUDAR

- 1º — Identificar se a variável é qualitativa, quantitativa ou temporal.
- 2º — Saber escolher o gráfico certo.
- 3º — Saber copiar e adaptar os códigos básicos.
- 4º — Saber interpretar média × mediana e assimetria.
- 5º — Saber interpretar Pearson.
- 6º — Saber ler tabela de porcentagem condicional.
- 7º — Saber ler boxplot e calcular AIQ.
- 8º — Só depois decorar detalhes como melt(), unstack() e resample().

26. ESTRATÉGIA PARA NÃO TRAVAR NA PROVA

1. Que tipo de variável tenho?
↓
2. Tenho uma ou duas variáveis?

- ↓
3. O que a questão está pedindo?
 - ↓
 4. Escolho o código correspondente.
 - ↓
 5. Troco VARIÁVEL pelo nome que aparece no CSV.
 - ↓
 6. Rodo o código.
 - ↓
 7. Olho o gráfico/tabela/número.
 - ↓
 8. ESCRIVO A INTERPRETAÇÃO.

Nunca entregue apenas o código se a questão pedir análise. O gabarito enfatiza a interpretação dos resultados.