

COLA DE PROVA — CÓDIGOS

1. IMPORTS + CSV

```
import pandas as pd
import altair as alt
alt.data_transformers.disable_max_rows()

dados = pd.read_csv('arquivo.csv', sep=';')
dados = pd.read_csv('arquivo.csv')

dados.head()
dados.dtypes

pd.set_option('display.max_columns', None)
```

2. QUALITATIVA — BARRAS

```
alt.Chart(dados).mark_bar().encode(
    alt.X("VARIABEL", sort='-y'),
    alt.Y('count()'),
    tooltip=['VARIABEL', 'count()']
)
```

3. QUALITATIVA — PIZZA

```
alt.Chart(dados).mark_arc().encode(
    theta="count()",
    color="VARIABEL",
    tooltip=['VARIABEL', 'count()']
)
```

4. DUAS QUALITATIVAS — TABELA

```
tabela_dupla_entrada = dados.groupby(
    ['VARIABEL1', 'VARIABEL2']
).size().unstack(1)

tabela_dupla_entrada.loc['Total',:] = tabela_dupla_entrada.sum(axis=0)
tabela_dupla_entrada.loc[:, 'Total'] = tabela_dupla_entrada.sum(axis=1)

tabela_dupla_entrada_pivot = pd.pivot_table(
    dados,
    index=['VARIABEL1', 'VARIABEL2'],
    aggfunc='size'
)

tabela_dupla_entrada_pivot
```

5. PORCENTAGEM CONDICIONAL

```
tabela_dupla_entrada_pivot / tabela_dupla_entrada_pivot.groupby(level=0).transform(sum) * 100

tabela_dupla_entrada_pivot / tabela_dupla_entrada_pivot.groupby(level=1).transform(sum) * 100
```

6. DUAS QUALITATIVAS — BARRAS

```
aux = (
    tabela_dupla_entrada_pivot /
    tabela_dupla_entrada_pivot.groupby(level=0).transform(sum) * 100
).reset_index().rename(columns={0: 'contagem'})

alt.Chart(aux).mark_bar().encode(
    x='VARIABEL1:N',
    y='contagem:Q',
    color='VARIABEL2:N'
)
```

7. QUANTITATIVA — DESCRIBE

```
dados["VARIABEL"].describe()
```

8. QUANTITATIVA — HISTOGRAMA

```
alt.Chart(dados).mark_bar().encode(
    alt.X("VARIABEL", bin=True),
    y='count()',
)
```

9. ORDENAR

```
dados[["VARIABEL1", "VARIABEL2"]].sort_values(
    "VARIABEL2",
    ascending=False
)
```

10. FILTRAR

```
dados[dados["VARIABEL"] > 45][
    ["VARIABEL1", "VARIABEL"]
]
```

11. DATA

```
dados['DATA'] = pd.to_datetime(
    dados['DATA']
)
```

12. SÉRIE TEMPORAL — LINHA

```
alt.Chart(dados).mark_line().encode(
    x='DATA',
    y=alt.Y('VARIABEL:Q'),
    tooltip=['DATA', 'VARIABEL']
)
```

13. MÉDIA MENSAL

```
dados_index = dados.set_index('DATA')

dados_mensal = dados_index.resample('M').VARIABEL.mean()

alt.Chart(dados_mensal.reset_index()).mark_line().encode(
    x='DATA',
    y=alt.Y('VARIABEL:Q'),
    tooltip=['DATA', 'VARIABEL']
)
```

14. SCATTERPLOT

```
alt.Chart(dados).mark_circle().encode(
    alt.X("VARIABEL_X"),
    alt.Y("VARIABEL_Y"),
    tooltip=[
        'VARIABEL1',
        'VARIABEL_X',
        'VARIABEL_Y'
    ]
)
```

15. PEARSON

```
dados[
    ['VARIABEL_X', 'VARIABEL_Y']
].corr(numeric_only=True)

dados.corr(numeric_only=True)
```

16. PEARSON SEM UM OUTLIER

```
dados[
    dados.Territorialidades!='NOME'
][
    ['VARIABEL_X', 'VARIABEL_Y']
].corr(numeric_only=True)
```

17. BOXPLOT — MELT

```
melted_data = dados.melt(
    id_vars=['Territorialidades'],
    value_vars=[
        'VARIABEL_1',
        'VARIABEL_2'
    ],
    var_name='Category',
    value_name='Value'
)
```

18. BOXPLOT

```
alt.Chart(melted_data).mark_boxplot(
    extent=1.5,
    size=40
).encode(
    alt.X("Value:Q"),
    alt.Y("Category:N"),
    tooltip=['Territorialidades']
).properties(
    height=200,
    width=600
)
```

19. AIQ

Q3 - Q1

20. EXEMPLOS DO GABARITO — ENEM

```
enem = pd.read_csv(
    'MICRODADOS_ENEM_2023_sample1_filtrado.csv',
    sep=';'
)

alt.Chart(enem).mark_bar().encode(
    alt.X("TP_COR_RACA", sort='-y'),
    alt.Y('count()'),
    tooltip=['TP_COR_RACA', 'count()']
).properties(width=300)

alt.Chart(enem).mark_arc().encode(
    theta="count()",
    color="TP_SEX0",
    tooltip=['TP_SEX0', 'count()']
)

tabela_dupla_entrada = enem.groupby(
    ['TP_COR_RACA', 'Q025']
).size().unstack(1)

tabela_dupla_entrada_pivot = pd.pivot_table(
    enem,
    index=['TP_COR_RACA', 'Q025'],
    aggfunc='size'
)

tabela_dupla_entrada_pivot / tabela_dupla_entrada_pivot.groupby(level=0).transform(sum) * 100

tabela_dupla_entrada_pivot / tabela_dupla_entrada_pivot.groupby(level=1).transform(sum) * 100
```

21. EXEMPLOS DO GABARITO — CLIMA

```
clima = pd.read_csv(
    'inmet_A652_2020_2025.csv',
    sep=';'
)

clima.head()
clima.dtypes

clima['DATA (YYYY-MM-DD)'] = pd.to_datetime(
    clima['DATA (YYYY-MM-DD)']
)

alt.Chart(clima).mark_line().encode(
    x='DATA (YYYY-MM-DD)',
    y=alt.Y('rain_max:Q'),
    tooltip=['DATA (YYYY-MM-DD)', 'rain_max']
)

alt.Chart(clima).mark_line().encode(
    x='DATA (YYYY-MM-DD)',
    y=alt.Y('temp_max:Q'),
    tooltip=['DATA (YYYY-MM-DD)', 'temp_max']
)

clima_index = clima.set_index('DATA (YYYY-MM-DD)')
```

```

clima_tempmax_mensal = clima_index.resample('M').temp_max.mean()
clima_rain_mensal = clima_index.resample('M').rain_max.mean()

```

22. EXEMPLOS DO GABARITO — CENSO

```

censo_municipios = pd.read_csv(
    'Censo_municipios_2010.csv'
)

censo_municipios.head()

alt.Chart(censo_municipios).mark_bar().encode(
    alt.X("Renda per capita 2010", bin=alt.Bin(step=100)),
    y='count()',
)

censo_municipios["Renda per capita 2010"].describe()

censo_municipios[[
    "Territorialidades",
    "Renda per capita 2010"
]].sort_values(
    "Renda per capita 2010",
    ascending=False
)

censo_estados = pd.read_csv(
    'Censo_estados_2010_desagregado.csv'
)

censo_estados.head()

alt.Chart(censo_estados).mark_circle().encode(
    alt.X("Renda per capita 2010"),
    alt.Y("Taxa de analfabetismo - 18 anos ou mais de idade 2010"),
    tooltip=[
        'Territorialidades',
        'Renda per capita 2010',
        'Taxa de analfabetismo - 18 anos ou mais de idade 2010'
    ]
)

censo_estados[
    [
        'Territorialidades',
        'Renda per capita 2010',
        'Taxa de analfabetismo - 18 anos ou mais de idade 2010'
    ]
].corr(numeric_only=True)

```

23. CENSO — BOX PLOT DO GABARITO

```

melted_data_renda_homem_mulher = censo_estados.melt(
    id_vars=['Territorialidades'],
    value_vars=[
        'Desagregação HOMEM Renda per capita Censo',
        'Desagregação MULHER Renda per capita Censo'
    ],
    var_name='Category',
    value_name='Value'
)

alt.Chart(melted_data_renda_homem_mulher).mark_boxplot(
    extent=1.5,
    size=40
).encode(
    alt.X("Value:Q"),
    alt.Y("Category:N"),
    tooltip=['Territorialidades']
).properties(
    height=200,
    width=600
)

melted_data_analf_branco_negro = censo_estados.melt(
    id_vars=['Territorialidades'],
    value_vars=[
        'Desagregação BRANCO Taxa de analfabetismo - 18 anos ou mais de idade Censo',
        'Desagregação NEGRO Taxa de analfabetismo - 18 anos ou mais de idade Censo'
    ]
)

```

```
    ],
    var_name='Category',
    value_name='Value'
)

alt.Chart(melted_data_analf_branco_negro).mark_boxplot(
    extent=1.5,
    size=40
).encode(
    alt.X("Value:Q"),
    alt.Y("Category:N")
)
```