

Guia de Consulta para a Prova

Métodos Estatísticos Aplicados às Ciências Sociais

Monitoria · Como ler a questão, que análise fazer e como interpretar

Como usar este guia

Cada bloco responde uma dúvida da prova. Leia na ordem na primeira vez; depois use como consulta rápida.

Não tem código aqui: o foco é **entender o que fazer e como explicar o resultado**. O código fica no seu próprio resumo, já testado.

Regra de ouro da professora: **sempre interprete e nunca esqueça as medidas de resumo** (centro, dispersão e, quando couber, a correlação de Pearson).

Sumário

1. Como ler o enunciado
2. Estratégia de prova
3. Como organizar o seu resumo
4. Dicionário de termos dos resultados
5. Medidas de resumo: centro e dispersão
6. Boxplot (diagrama de caixa)
7. Análise bivariada
8. Catálogo de gráficos e análises da matéria
9. Checklist rápido antes de entrar na prova

1. Como ler o enunciado

Antes de abrir o Colab, "garimpe" a questão. Leia o enunciado procurando três coisas:

1. **Quais variáveis aparecem** e de que tipo cada uma é.
2. **Quais pares de variáveis** faz sentido cruzar.
3. **Que tipo de pergunta** está sendo feita: descrever, comparar grupos ou medir relação.

1.1 Os quatro tipos de variável

Tipo	O que é	Exemplos das bases da matéria
Qualitativa nominal	Categorias sem ordem	cor/raça, gênero, UF, tipo de escola, tem internet?
Qualitativa ordinal	Categorias com ordem	faixa etária, escolaridade do pai/mãe, faixa de renda familiar
Quantitativa discreta	Número que vem de contagem (valores "pulados")	nº de filhos, nº de homicídios
Quantitativa contínua	Número que vem de medição (qualquer valor num intervalo)	renda per capita, notas do ENEM, taxas (%), temperatura, chuva

Pegadinhas clássicas

Número nem sempre é quantitativo. A faixa etária do ENEM vem como 1, 2, 3..., mas cada número é o código de uma faixa (ordinal). O número de inscrição é só uma identificação. Tirar média disso não faz sentido.

Faixas de valores viram ordinal. A renda familiar em faixas (A, B, C...) é qualitativa ordinal, não quantitativa.

Taxas e percentuais são quantitativos contínuos (analfabetismo, mortalidade infantil).

1.2 Que pergunta é essa? Qual caminho seguir?

O tipo das variáveis decide a análise. Use esta tabela como bússola:

Tipo de pergunta	Variáveis	Análise / tabela	Gráfico	Medida
Descrever uma variável	1 qualitativa	Distribuição de frequência (nº e %)	Barras (ou setores)	Percentuais; categoria mais comum
Descrever uma variável	1 quantitativa	Forma, centro, dispersão e atípicos	Histograma (e boxplot)	Média, mediana, desvio padrão, quartis, AIQ
Ver evolução no tempo	1 quantitativa + data	Série temporal (pode agrupar por mês)	Linha	Tendência, ciclos, desvios, dados faltantes
Comparar grupos	1 quantitativa + 1 qualitativa	Resumo por grupo	Boxplots lado a lado	Mediana e AIQ de cada grupo
Medir associação	2 qualitativas	Tabela de dupla entrada + %	Barras segmentadas 100%	Percentuais condicionais

Tipo de pergunta	Variáveis	Análise / tabela	Gráfico	Medida
Medir correlação	2 quantitativas	Relação entre as duas	Dispersão	Coeficiente de Pearson (r)

1.3 Garimpando questões reais (prova do ano passado)

Três exemplos, resumidos com as nossas palavras, de como pensar antes de fazer qualquer coisa.

Exemplo A: a questão do ENEM

- **O que o enunciado trazia:** uma amostra de participantes do ENEM com faixa etária, gênero, cor/raça, tipo de escola, UF, as notas de cada prova e perguntas do questionário (escolaridade dos pais, renda familiar em faixas, se a casa tem internet etc.).
- **Garimpo dos tipos:** gênero, cor/raça, escola, UF e internet → nominais. Faixa etária, escolaridade dos pais e faixa de renda → ordinais (mesmo que venham como número ou letra). Notas → quantitativas contínuas.
- **O que pediam:** (1) descrever duas variáveis qualitativas à escolha → **descrever** → barras ou setores com %; (2) cruzar cor/raça com acesso à internet → **duas qualitativas** → tabela de dupla entrada + barras segmentadas.
- **Par que também seria interessante:** nota de Matemática × nota de Ciências da Natureza (duas quanti → dispersão + Pearson).

Exemplo B: a questão da PNAD (sem base de dados)

- **O que o enunciado trazia:** só dois números sobre a renda domiciliar per capita do Brasil: a média era bem maior que a mediana.
- **Garimpo:** uma variável quantitativa contínua (renda). Não há gráfico a fazer.
- **O que pediam:** o que esses números dizem sobre a distribuição → **descrever uma variável** usando teoria: média > mediana → assimetria à direita → poucas rendas muito altas puxam a média → desigualdade.
- **Lição:** nem toda questão pede código. Às vezes é só aplicar a regra de média × mediana (Bloco 5).

Exemplo C: a questão do Censo por estados

- **O que o enunciado trazia:** indicadores sociais por estado (esperança de vida, mortalidade infantil, analfabetismo, renda per capita), também separados para homens, mulheres, brancos e negros.
- **Garimpo:** todos os indicadores são quantitativos contínuos. Os grupos (homem/mulher, branco/negro) são qualitativos nominais, só que "escondidos" nos nomes das colunas.
- **O que pediam:** (1) relacionar dois indicadores → **duas quanti** → dispersão + Pearson (e checar valores atípicos, como o Distrito Federal); (2) comparar um indicador entre homens e mulheres, e outro entre brancos e negros → **quanti × quali** → boxplots lado a lado com a regra 1,5×AIQ.
- **Dica:** quando o enunciado já diz o gráfico ("use boxplots"), siga exatamente o que foi pedido.

Havia ainda uma questão de clima (dados diários de uma estação meteorológica): uma variável quantitativa medida ao longo do tempo → **série temporal** → gráfico de linha e leitura de ciclos e falhas nos dados.

2. Estratégia de prova

Regra	Na prática
Escolha o caminho mais simples	Se duas abordagens respondem a mesma pergunta, use a que você domina com mais segurança. Nota vem da análise correta e bem explicada, não do gráfico mais sofisticado. NAO TENHA VERGONHA DE REPETIR GRAFICOS PRA ANALISES DIFERENTES, se apropriado.
Comece pelo que você sabe	Leia a prova inteira, resolva primeiro as questões mais familiares e deixe as incertas para o final. Não deixe nenhuma em branco: em branco conta como errada.
Só faça gráficos já testados	Use apenas tipos de gráfico que você já rodou antes e sabe que funcionam. O dia da prova não é hora de testar gráfico novo.
Interprete sempre	Todo resultado (tabela, gráfico, número) precisa de pelo menos uma frase explicando o que ele mostra, com números.
Não esqueça as medidas de resumo	Centro (média/mediana), dispersão (desvio padrão/AIQ) e, se forem duas quanti, o r de Pearson.
Confira a entrega	Antes de enviar, verifique se os resultados (gráficos e tabelas) aparecem no arquivo salvo.

Boa prática de estudo: use o gabarito do ano passado como modelo

Os gráficos do gabarito da prova passada mostram **como montar cada tipo de gráfico** que costuma cair (barras, setores, histograma, linha, boxplots lado a lado, barras segmentadas, dispersão).

Use esses gráficos como referência para praticar: tente refazer cada um sozinho(a), numa base de aula, e só depois compare. O objetivo é aprender o "molde", não decorar a resposta.

Atenção às regras

Na prova do ano passado era permitido consultar materiais, anotações e internet, mas **era proibido usar colegas e IAs** (ChatGPT, Claude, Gemini etc.). Monte seu resumo com antecedência: na hora, você consulta o que já preparou.

3. Como organizar o seu resumo

3.1 Estrutura em blocos

Separe o resumo em blocos, um por tema. Uma sugestão que segue a ordem lógica da matéria e da prova do ano passado:

Bloco	Tema	O que deve ter
0	Preparação	Importar as bibliotecas, ler a base (atenção ao separador), primeira olhada nos dados
1	Tipos de variáveis	Tabela com as variáveis das bases de aula e seus tipos
2	Univariada qualitativa	Frequências (nº e %), barras e setores, frase-modelo
3	Univariada quantitativa e medidas de resumo	Histograma, resumo estatístico, AIQ, regra 1,5×AIQ
4	Boxplot	Boxplot simples e lado a lado (incluindo a transformação da base para o formato "longo")
5	Série temporal	Conversão da coluna de data, gráfico de linha, agrupamento por mês
6	Tabela de dupla entrada	Contagens, % por linha e por coluna, barras segmentadas
7	Dispersão e Pearson	Gráfico de dispersão, cálculo de r, recálculo sem atípico
8	Roteiro final	Tabela "tipo de pergunta → análise → gráfico → medida" (Bloco 1.2 deste guia)

3.2 Boas práticas para cada bloco

- **Guarde os resultados junto com o código.** Deixe visível o gráfico ou a tabela que saiu. Ver o resultado é o que te dá confiança de que aquele trecho funciona.
- **Nomes claros.** Dê nomes descritivos aos resultados: "renda_porsexo" é melhor que "df2" ou "x". Evite abreviações que você não vai lembrar.
- **Comente o porquê, não o como.** Ao lado de cada passo, escreva o objetivo: "comparar a renda de homens e mulheres", e não "faz um melt". Na prova, você acha o bloco certo pela finalidade.
- **Teste tudo antes.** Código nunca rodado costuma falhar na hora. Rode cada bloco numa base de aula.
- **Escreva a interpretação com suas palavras** e deixe uma frase-modelo com lacunas, ex.: "A mediana de [grupo A] é [valor], maior que a de [grupo B]...".
- **Teste o resumo.** Resolva uma prova antiga usando só ele. O que você precisou procurar fora é o que está faltando.

Segue o trecho revisto. Agora ele fala dos materiais para anexar e troca o prompt pronto por um roteiro que o aluno monta do seu jeito.

3.3 Usando IA para montar o resumo (antes da prova)

A IA serve para **estudar e montar** o resumo. Na hora da prova, você só consulta o que já preparou. No ano passado era proibido usar IA durante a avaliação.

1. Dê material de base para a IA

A IA responde melhor quando trabalha em cima do **material da disciplina**, e não só do que ela "acha" que cai. Antes de pedir qualquer coisa, anexe ou cole:

- **A prova do ano passado com o gabarito.** Ela mostra que tipo de pergunta cai, quais bases aparecem e como a professora espera a interpretação.
- **Este guia de consulta.** Ele já traz a estrutura dos temas, o glossário e o roteiro "tipo de pergunta → análise → gráfico → medida".
- **As aulas do GitHub da disciplina** (os notebooks). São a referência de código e de linguagem que a professora usa. Se a IA não conseguir abrir o link, baixe os notebooks e anexe os arquivos, ou cole o trecho da aula que interessa.

No seu pedido, deixe claro que a IA deve **usar esses materiais como base**: seguir a forma de fazer das aulas e do gabarito, e avisar quando sugerir algo que não aparece neles.

2. O que buscar em cada tema

Um bom resumo não é só código. Para cada tema, procure ter:

- a **ideia** explicada de forma simples;
- a **definição e as fórmulas**, com o significado de cada símbolo;
- um **exemplo pequeno** com a conta feita à mão;
- um **modelo de código** genérico e comentado, no mesmo estilo das aulas;
- **como interpretar** o resultado, com uma frase-modelo para preencher;
- os **erros comuns** do tema.

3. Use o gabarito como molde, não como cola

- **Tente refazer** cada gráfico do gabarito numa base de aula, e só depois compare.
- Peça para a IA explicar **por que** cada análise foi escolhida para cada pergunta, e não só o que o código faz.
- Repare em **como a interpretação foi escrita**: sempre com números, medidas de resumo e a menção aos valores atípicos.
- A prova deste ano terá outras bases e outras perguntas. O que se aproveita é o raciocínio.

4. Monte o seu próprio prompt

Não existe prompt certo. O melhor é o que parte do que **você** precisa. Use este roteiro para escrever o seu:

- **Contexto:** diga que é a prova de Métodos Estatísticos, feita no Colab com pandas e altair, com consulta. Avise que vai anexar a prova antiga com gabarito, o guia e as aulas, e peça que a IA use esses materiais como base.
- **Seu ponto de partida:** o que você já domina e onde trava. Por exemplo, "entendo a teoria mas erro o código", "não sei quando usar cada gráfico" ou "travo na interpretação".
- **Como você aprende melhor:**
 - com gráficos e exemplos visuais?
 - com a lógica e as fórmulas primeiro?
 - com analogias do dia a dia?
 - com exercícios para praticar?
- Peça a explicação nesse formato.
- **Recorte:** escolha **um tema por vez**, começando pelos que você menos domina (a lista de temas está no Bloco 3.1 deste guia). Pedir tudo de uma vez gera respostas longas e rasas.
- **Formato da resposta:** diga como quer receber o conteúdo para colar no resumo, por exemplo "teoria curta em tópicos, depois o código comentado, depois uma frase-modelo de

interpretação".

- **Regras:** peça exemplos pequenos e fictícios (sem inventar dados reais), no mesmo estilo de código das aulas, e que a IA avise quando algo depender da versão do pandas.

Um começo possível, para você completar do seu jeito: *"Estou montando meu resumo de consulta para [tema]. Anexei [materiais]. Tenho dificuldade em [ponto] e aprendo melhor com [formato]. Usando os materiais como base, me ajude a..."*

5. Continue a conversa

A primeira resposta raramente é a final. Aprofunde com pedidos como:

- explicar de novo de outro jeito;
- passar exercícios sem resposta e depois corrigir os seus;
- comparar dois conceitos parecidos;
- revisar um parágrafo de interpretação que você escreveu;
- explicar um erro de código que apareceu;
- dizer por que o gabarito usou uma análise e não outra.

6. Transforme a resposta em resumo

- **Teste os códigos** no Colab com uma base de aula antes de colocar no resumo.
- **Reescreva com suas palavras**, principalmente a interpretação: é ela que vale nota.
- **Organize para achar rápido:** índice no topo, uma célula por tema, teoria em texto, código logo abaixo e resultados visíveis.
- **Teste o resumo:** resolva a prova passada usando só ele. O que você precisou procurar em outro lugar é o que está faltando.

Checklist do resumo pronto

- ☐ Tem índice e está dividido por tema.
- ☐ Cada tema tem teoria, exemplo, código testado (com resultado visível) e modelo de interpretação.
- ☐ Tem a tabela "tipo de pergunta → análise → gráfico → medida".
- ☐ Os nomes das bases e colunas usadas em aula estão anotados.
- ☐ Você refez os gráficos do gabarito sem olhar.
- ☐ Você resolveu pelo menos uma prova antiga usando só o resumo.

4. Dicionário de termos dos resultados

Tradução, em português simples, das palavras que aparecem nos resultados do Colab.

4.1 Resumo estatístico (describe)

Termo	Tradução	O que significa na prática
describe()	resumo estatístico	Gera de uma vez as medidas abaixo para cada coluna numérica.
count	contagem	Quantas observações (linhas com valor) existem. Serve para saber o tamanho do grupo.
mean	média	Soma de tudo dividida pelo número de observações. É "puxada" por valores extremos.
std	desvio padrão	Distância típica de cada valor até a média. Quanto maior, mais espalhados os dados.
min / max	mínimo / máximo	Menor e maior valor. A diferença entre eles é a amplitude.
25%	1º quartil (Q1)	25% dos dados estão abaixo deste valor.
50%	2º quartil = mediana	O valor do meio: metade dos dados abaixo, metade acima.
75%	3º quartil (Q3)	75% dos dados estão abaixo deste valor.
median	mediana	Mesmo que o 50%. Não é afetada por valores extremos.
var	variância	Desvio padrão ao quadrado. Pouco usada para interpretar (unidade fica ao quadrado).

4.2 Inspeção da base

Termo	Tradução	O que significa na prática
.head()	cabeçalho	Mostra as primeiras linhas da base. Serve para conferir se os dados foram carregados certo.
shape	formato	(nº de linhas, nº de colunas) da base.
columns	colunas	Lista os nomes das colunas. Copie daqui para não errar acento ou espaço.
dtypes / dtype	tipo do dado	Diz como o computador guardou cada coluna (ver linhas abaixo).
int64	número inteiro	Coluna numérica sem casas decimais (atenção: pode ser um código!).
float64	número decimal	Coluna numérica com casas decimais.
object / str	texto	Coluna de texto ou categoria.
datetime64	data	Coluna reconhecida como data. Necessária para série temporal.
Unnamed: 0	coluna sem nome	Coluna de numeração que veio do arquivo. Pode ignorar.

Termo	Tradução	O que significa na prática
NaN	valor ausente	Célula vazia (dado faltando).
sep	separador	Caractere que separa as colunas no arquivo (vírgula ou ponto e vírgula). Se errar, a base aparece toda numa coluna só.
Name: ... , dtype: float64	rodapé do resultado	Só informa o nome da coluna e o tipo do resultado. Não precisa interpretar.
Length	tamanho	Quantas linhas o resultado tem (quando o Colab esconde o meio com "...").

4.3 Contagens, grupos e tabelas

Termo	Tradução	O que significa na prática
value_counts	contagem por categoria	Quantas vezes cada categoria aparece. É a distribuição de frequência.
normalize	em proporção	Mostra proporções (somam 1) em vez de contagens. Multiplique por 100 para ter %.
groupby	agrupar por	Separa a base em grupos (ex.: por sexo) para calcular algo em cada um.
crosstab	tabela cruzada	Monta a tabela de dupla entrada entre duas qualitativas.
index / columns	por linha / por coluna	Em que direção os percentuais somam 100%.
All / Total / margins	totais	Linha e coluna de totais da tabela.
melt	"derreter" a base	Passa colunas lado a lado (ex.: renda homem renda mulher) para uma coluna de grupo + uma de valor. Necessário para boxplots lado a lado.
Category / Value	grupo / valor	Nomes das colunas que o melt cria.

4.4 Correlação, gráficos e tempo

Termo	Tradução	O que significa na prática
corr	correlação	Calcula o coeficiente de Pearson (r) entre colunas numéricas.
matriz de correlação	tabela de r	Cada célula é o r entre duas variáveis. A diagonal é sempre 1 (variável com ela mesma).
r	coeficiente de Pearson	Número de -1 a 1 que mede direção e força da relação linear.
AIQ (IQR em inglês)	amplitude interquartil	$Q3 - Q1$: o tamanho da metade central dos dados.
outlier	valor atípico	Valor muito afastado do resto. Pela regra: abaixo de $Q1 - 1,5 \times AIQ$ ou acima de $Q3 + 1,5 \times AIQ$.
extent=1.5	regra $1,5 \times AIQ$	Faz o boxplot marcar os atípicos com essa regra.

Termo	Tradução	O que significa na prática
bin	classe / intervalo	Faixas do histograma. Mudar a largura muda a "cara" do gráfico.
count()	contagem	Altura das barras é o número de observações.
stack="normalize"	empilhado em 100%	Cada barra vai até 100%. Serve para comparar proporções.
tooltip	etiqueta ao passar o mouse	Mostra quem é cada ponto (útil para identificar atípicos).
to_datetime	converter para data	Transforma texto em data.
resample / ME / YE	agrupar por período	Junta dados diários por mês (ME) ou ano (YE).
Freq: ME	frequência mensal	Aviso de que o resultado está agrupado por mês.
FutureWarning	aviso de versão	Não é erro: o resultado sai certo; só avisa que o comando vai mudar no futuro.

5. Medidas de resumo: centro e dispersão

Para descrever uma variável quantitativa, diga sempre três coisas: **forma** (o desenho do histograma), **centro** (o valor típico) e **dispersão** (o quanto os valores variam), além dos valores atípicos.

5.1 Medidas de centro: "qual é o valor típico?"

Medida	O que é	Quando usar
Média	Soma de todos os valores dividida pela quantidade. É o "ponto de equilíbrio".	Dados simétricos, sem valores extremos. Ela é puxada por extremos (não é resistente).
Mediana	O valor do meio depois de ordenar os dados.	Dados assimétricos ou com atípicos (ex.: renda). Resistente : extremos quase não a mudam.
Moda	O valor ou a categoria mais frequente.	Principalmente para variáveis qualitativas ("a categoria mais comum é...").

Exemplo rápido (da aula): livros lidos no ano por 7 pessoas

Valores: 2, 4, 4, 5, 7, 9, 30. Média $\approx 8,7$ e mediana = 5.

Sem o 30: a média cai para $\approx 5,2$ (caiu 3,5), a mediana vai para 4,5 (caiu só 0,5). **Isso é resistência.**

Média × mediana revelam a forma:

Comparação	Forma da distribuição	O que dizer
média $\approx$ mediana	Simétrica	Os dois lados são parecidos.
média $>$ mediana	Assimétrica à direita	Poucos valores muito altos puxam a média para cima (típico de renda → desigualdade).
média $<$ mediana	Assimétrica à esquerda	Poucos valores muito baixos puxam a média para baixo.

5.2 Medidas de dispersão: "o quanto os dados variam?"

Medida	O que diz	Cuidado
Amplitude (máx – mín)	Distância entre o menor e o maior valor.	Depende só de dois valores; muito afetada por atípicos.
Intervalo interquartil – AIQ (Q3 – Q1)	Tamanho da faixa onde estão os 50% centrais.	Resistente. Par ideal da mediana.
Desvio padrão	Distância típica de um valor até a média, na mesma unidade dos dados.	Não é resistente. Par ideal da média.
Variância	Desvio padrão ao quadrado.	Unidade ao quadrado; difícil de interpretar. Prefira o desvio padrão.

Qual par de medidas usar?

Distribuição **simétrica** e sem atípicos → **média + desvio padrão**.

Distribuição **assimétrica** ou com atípicos → **mediana + AIQ** (e o resumo dos 5 números: mínimo, Q1, mediana, Q3, máximo).

Valor atípico (regra 1,5×AIQ): abaixo de $Q1 - 1,5 \times AIQ$ ou acima de $Q3 + 1,5 \times AIQ$. Sempre diga quem é o atípico.

5.3 Lendo uma tabela de resumo em 4 passos

Exemplo real (aula e prova): renda per capita dos 5.565 municípios, Censo 2010.

count	mean	std	min	25%	50%	75%	max
5.565	493,61	243,27	96,25	281,12	467,65	650,62	2.043,74

1. **Compare média e mediana:** $493,61 > 467,65$ → assimetria à direita.
2. **Escolha a medida de centro:** assimétrica → mediana: metade dos municípios tinha renda abaixo de R\$ 467,65.
3. **Veja a dispersão:** amplitude enorme (R\$ 96 a R\$ 2.044), mas a metade central fica entre R\$ 281 e R\$ 651 (AIQ = R\$ 369,50).
4. **Procure atípicos:** cerca superior = $650,62 + 1,5 \times 369,50 \approx \text{R\$ } 1.205$ → municípios acima disso são atípicos (ex.: São Caetano do Sul e Niterói).


Conclusão em uma frase

"A renda per capita municipal é assimétrica à direita: a maioria dos municípios tem renda baixa (mediana de R\$ 468) e poucos têm renda muito alta, o que indica desigualdade territorial."

6. Boxplot (diagrama de caixa)

O boxplot é o desenho do resumo dos 5 números. Em uma imagem, ele mostra centro, dispersão, forma e atípicos.

Anatomia do boxplot (diagrama de caixa)



Cada parte do boxplot e o que ela representa.

6.1 As partes

Parte	O que representa
Linha dentro da caixa	A mediana (o valor do meio).
Caixa	Vai do Q1 ao Q3. Contém os 50% centrais. O comprimento dela é o AIQ.
Bigodes (linhas laterais)	Vão até o menor e o maior valor que não são atípicos.
Pontos soltos	Valores atípicos, pela regra 1,5×AIQ.


6.2 Como interpretar

- **Centro**: onde está a linha da mediana.
- **Dispersão**: caixa comprida = dados espalhados; caixa curta = dados concentrados.
- **Forma**: se a mediana está mais perto do Q1 e o lado direito (caixa + bigode) é mais longo → **assimetria à direita**. Se estiver no meio → simétrica.
- **Atípicos**: existem? Quem são? (Ex.: o Distrito Federal na renda por estado.)

6.3 Boxplots lado a lado: comparando grupos

Quando usar: uma variável **quantitativa** comparada entre grupos de uma **qualitativa** (nominal ou ordinal). Ex.: renda de homens × mulheres; analfabetismo de brancos × negros.

Boxplots lado a lado: a caixa dos negros está deslocada para a direita



Dados reais da aula: taxa de analfabetismo por estado, brancos × negros (Censo 2010).

Compare sempre nesta ordem:

1. **Centro:** qual mediana é maior? Por quanto? (negros $\approx 10,9\%$ × brancos $\approx 6,7\%$: mais de 4 pontos percentuais de diferença)
2. **Dispersão:** qual caixa é mais comprida (maior AIQ)? (parecidas, mas a dos negros vai até valores bem mais altos)
3. **Forma:** as duas são assimétricas? Para que lado? (ambas à direita)
4. **Atípicos:** algum grupo tem? Quem é?

Frase-modelo

"A distribuição de [variável] para [grupo A] está deslocada para a [direita/esquerda] em relação a [grupo B]: a mediana é [valor A] contra [valor B]. A dispersão (AIQ) é [maior/parecida/menor]. Ambas são [simétricas/assimétricas à ...] e [há/não há] valores atípicos ([quem])."

7. Análise bivariada

Bivariada = olhar **duas variáveis juntas** para saber se elas estão associadas: conhecer o valor de uma muda o que esperamos da outra?

- **Variável explicativa:** a que ajuda a explicar a outra (vai no eixo x; é o grupo pelo qual se calcula o %).
- **Variável resposta:** o resultado que queremos entender (vai no eixo y).
- Se não houver uma relação clara de explicação, escolha uma e **diga qual escolheu e por quê**.

7.1 Tabela de dupla entrada (qualitativa × qualitativa)

As linhas são as categorias de uma variável, as colunas as da outra, e cada célula conta quantas pessoas estão nas duas categorias ao mesmo tempo.

Exemplo da aula: 200 estudantes, tipo de escola × aprovação no vestibular.

	Aprovado: Não	Aprovado: Sim	Total
Pública	84	36	120
Privada	40	40	80
Total	124	76	200

Os três tipos de percentual

Tipo	Divide por	Exemplo	Responde
Conjunta	o total geral	Pública e aprovado: $36/200 = 18\%$	Qual % do total está nessa combinação?
Marginal	o total geral, usando só os totais	Pública: $120/200 = 60\%$	Como se distribui cada variável sozinha?
Condicional	o total da linha (ou da coluna)	Aprovados na pública: $36/120 = 30\%$; na privada: $40/80 = 50\%$	Dentro de cada grupo, como está a outra variável? É o que mostra associação.

Como ler e o que procurar

Calcule o % dentro de cada grupo da explicativa (condicional). Aqui: 30% de aprovação na pública × 50% na privada → **há associação** (20 pontos percentuais de diferença).

Não compare contagens brutas quando os grupos têm tamanhos diferentes: 36 × 40 aprovados parece quase igual, mas os grupos têm 120 e 80 alunos.

Sem associação, os percentuais seriam iguais (ou bem parecidos) em todos os grupos.

Se a questão não disser a direção, faça o % **por linha e por coluna** e interprete os dois (como no gabarito).


Cuidado com uma terceira variável escondida que pode explicar a associação (Paradoxo de Simpson).

7.2 Diagrama de dispersão (quantitativa × quantitativa)

Cada observação vira um ponto: posição horizontal = valor de x, vertical = valor de y. A "nuvem" mostra se as variáveis andam juntas. Leia com o roteiro **D-F-I + O**:

Aspecto	Pergunta	Respostas possíveis
Direção	Quando x aumenta, y tende a...	subir (positiva), descer (negativa), sem direção clara
Forma	Que desenho a nuvem faz?	reta (linear), curva, grupos separados
Intensidade	Os pontos ficam perto do desenho?	forte (nuvem estreita), moderada, fraca (nuvem espalhada)
Outliers	Algum ponto fora do padrão?	diga quem é (ex.: Distrito Federal)

Diagrama de dispersão: padrões típicos e o valor de r (dados ilustrativos)




Padrões típicos de nuvem de pontos e o r de cada um.

7.3 Coeficiente de correlação de Pearson (r)

O r resume em **um número** a **direção** e a **força** da relação **linear** (em linha reta) entre duas variáveis **quantitativas**.

Como ler o coeficiente de Pearson (r)




Convenção usada na disciplina para classificar a intensidade.

- **Sinal:** positivo = sobem juntas; negativo = uma sobe, a outra desce.
- **Tamanho:** perto de 1 ou -1 = pontos quase numa reta; perto de 0 = pouca relação **linear**.
- **Como escrever:** direção + intensidade + valor. Ex.: "correlação negativa e forte (r = -0,79)".

Propriedade / limitação	O que significa
Vai de -1 a 1	± 1 só se todos os pontos estiverem exatamente numa reta.
Não tem unidade	Trocar reais por dólares ou °C por °F não muda o r.
É simétrico	r de x com y = r de y com x.
Só para duas quantitativas	Não existe Pearson entre cor/raça e internet (use tabela de dupla entrada).
Só mede relação em linha reta	Uma relação curva forte pode ter r perto de 0. Sempre olhe o gráfico.
Sensível a atípicos	Um único ponto pode mudar muito o r. Recalcule sem ele e compare.

Propriedade / limitação	O que significa
Correlação não é causalidade	Andar junto não quer dizer que uma causa a outra. Sorvete e afogamentos sobem juntos por causa do calor (uma terceira variável).



Exemplo da aula: um único aluno atípico derruba o r de 0,96 para 0,29.

Exemplo real (prova): renda × analfabetismo nos estados

Dispersão: direção negativa, forma aproximadamente linear, intensidade forte. $r = -0,79$.

O Distrito Federal é atípico (renda bem acima do padrão). Sem ele, $r = -0,88$: a relação fica ainda mais forte.


Conclusão: estados com maior renda tendem a ter menos analfabetismo, **mas isso não prova causa.**

8. Catálogo de gráficos e análises da matéria

Uma ficha por gráfico: para que serve, quando usar e como ler.

8.1 Gráfico de barras

Para que serve	Quando usar
Mostrar quantas observações há em cada categoria.	1 variável qualitativa (nominal ou ordinal).



Barras ordenadas da maior para a menor (variável nominal). O rótulo é o % de cada categoria.

Dados reais da prova: cor/raça dos participantes do ENEM 2023 (amostra).


Como interpretar:

- Qual categoria é a maior e qual é a menor? Cite os **percentuais**, não só "a maioria".
- Nominal: ordene da maior para a menor barra. Ordinal: mantenha a ordem natural (ex.: faixas de renda).
- Se houver muito "Não respondeu", comente que isso limita a conclusão.

8.2 Gráfico de setores (pizza)

Para que serve	Quando usar
Mostrar como um todo (100%) se divide em partes.	1 variável qualitativa com poucas categorias que somam 100%.

Gráfico de setores: como 10 alunos chegam à faculdade



Exemplo da aula: meio de transporte de 10 estudantes.


Como interpretar:

- Qual fatia é maior? Qual o % de cada uma?
- Com muitas categorias ou fatias parecidas, prefira barras (mais fácil de comparar).

8.3 Histograma

Para que serve	Quando usar
Mostrar a forma de uma variável numérica: onde os valores se concentram e como se espalham.	1 variável quantitativa . Sempre acompanhe do resumo estatístico.

Histograma: as três formas mais comuns (dados ilustrativos)




As três formas mais comuns, com a posição da média e da mediana.

Como interpretar:

- **Forma:** simétrica, assimétrica à direita (cauda para valores altos) ou à esquerda.
- **Picos:** um só (unimodal) ou dois (bimodal)?
- **Centro e dispersão:** use média e desvio padrão (se simétrica) ou mediana e AIQ (se assimétrica).
- **Atípicos:** barras isoladas longe do resto. A largura das barras (classes) muda o desenho: teste algumas.

8.4 Boxplot e boxplots lado a lado

Para que serve	Quando usar
Resumir uma variável numérica em 5 números e comparar grupos.	1 quantitativa (sozinha) ou 1 quantitativa × 1 qualitativa (lado a lado).



Detalhes no Bloco 6.

Como interpretar:

- Compare mediana, tamanho da caixa (AIQ), forma e atípicos, nessa ordem.
- Use a regra $1,5 \times \text{AIQ}$ para marcar os atípicos e diga quem são.

8.5 Gráfico de linha (série temporal)

Para que serve	Quando usar
Mostrar como uma variável muda ao longo do tempo .	1 variável quantitativa medida em datas (dias, meses, anos). A coluna precisa estar como data.



Exemplo da aula: vendas de sorvete por trimestre.

Como interpretar:

- **Tendência:** no longo prazo, sobe, desce ou fica estável?
- **Ciclos/sazonalidade:** há padrões que se repetem (ex.: picos todo verão)?

- **Desvios:** picos ou quedas fora do padrão e **períodos sem dados** (buracos na linha). Mencione sempre.
- Dados diários são "barulhentos": agrupar por mês (média mensal) facilita ver o padrão.

8.6 Tabela de dupla entrada


Para que serve	Quando usar
Contar as combinações de categorias de duas variáveis.	2 qualitativas.

Como interpretar:

- Calcule os percentuais **dentro de cada grupo** (condicional) e compare.
- Percentuais diferentes entre os grupos → há associação. Detalhes no Bloco 7.1.

8.7 Barras segmentadas (empilhadas) 100%

Para que serve	Quando usar
Visualizar a tabela de dupla entrada em percentuais: cada barra é um grupo e vai até 100%.	2 qualitativas. É o melhor gráfico para ver associação.




Dados reais da prova: acesso à internet dentro de cada cor/raça (ENEM 2023).

Como interpretar:

- Se não houvesse associação, a divisão de cores estaria **no mesmo lugar** em todas as barras.
- Quanto mais as divisões ficam desalinhadas, mais forte a associação. Aqui, 23,4% dos indígenas não têm internet, contra 5,2% dos brancos.
- A versão com contagens absolutas mostra o tamanho dos grupos, mas é ruim para comparar proporções.

8.8 Barras lado a lado (agrupadas)

Para que serve	Quando usar
Alternativa às barras segmentadas: uma barra para cada combinação, com o % condicional.	2 qualitativas , com poucas categorias.




Exemplo da aula: % de aprovação dentro de cada tipo de escola.

Como interpretar:

- Compare a altura da mesma resposta entre grupos: 30% de aprovados na pública × 50% na privada.

8.9 Diagrama de dispersão

Para que serve	Quando usar
Mostrar a relação entre duas variáveis numéricas.	2 quantitativas. Sempre acompanhe do r de Pearson.




Detalhes no Bloco 7.2.

Como interpretar:

- Use o roteiro D-F-I + O: direção, forma, intensidade e outliers.
- Com milhares de pontos, pontos mais transparentes ajudam a ver onde a nuvem é mais densa.
- Colorir os pontos por uma categoria (ex.: região) pode revelar grupos.

8.10 Matriz de correlação e mapa de calor

Para que serve	Quando usar
Ver o r de várias variáveis numéricas, todas contra todas, de uma vez.	3 ou mais quantitativas. Útil para escolher o par mais interessante.



Dados reais da aula: indicadores dos estados, Censo 2010.

Como interpretar:

- A diagonal é sempre 1 (cada variável com ela mesma). A tabela é espelhada.
- Cores fortes = relação forte. Azul = positiva; laranja = negativa.
- Ex.: esperança de vida $\times$ mortalidade infantil, $r = -0,92$ (a relação mais forte, negativa).
- Antes de concluir, olhe a dispersão do par: o r sozinho pode enganar.

9. Checklist rápido antes de entrar na prova

Antes da prova

- ☐ Meu resumo está em blocos por tema, com índice, e cada bloco mostra o resultado já rodado.
- ☐ Testei todos os gráficos que pretendo usar (e só vou usar esses).
- ☐ Resolvi a prova do ano passado usando só o meu resumo.
- ☐ Sei ler a base com o separador certo e converter a coluna de data.

Durante a prova

- ☐ **Li a prova inteira** e comecei pelas questões mais fáceis.
- ☐ **Garimpei o enunciado:** listei as variáveis e o tipo de cada uma (nominal, ordinal, discreta, contínua).
- ☐ **Identifiquei a pergunta:** descrever? comparar grupos? medir associação/correlação?
- ☐ **Escolhi o caminho mais simples** que responde à pergunta (Bloco 1.2).
- ☐ Fiz exatamente o gráfico que o enunciado pediu, quando ele pediu um.
- ☐ Coloquei **medidas de resumo:** centro, dispersão e, se forem duas quanti, o r de Pearson.
- ☐ Usei **mediana e AIQ** quando a distribuição é assimétrica ou tem atípicos.
- ☐ Comparei **percentuais**, e não contagens, entre grupos de tamanhos diferentes.
- ☐ Olhei o gráfico antes de confiar no r , e recalculei sem o atípico quando havia um.
- ☐ Disse **quem** são os valores atípicos.
- ☐ **Interpretei tudo** com frases e números, e não falei em causa quando só há correlação.
- ☐ Não deixei nenhuma questão em branco.
- ☐ Conferi se os gráficos e tabelas aparecem no arquivo salvo antes de enviar.